


TOKEN REUSE EVIDENCE REPORT

RELATÓRIO DE EVIDÊNCIA DE REUTILIZAÇÃO DE TOKENS

Simplicio MCP - Technical analysis of a recorded execution summary
Simplicio MCP - Análise técnica de um resumo de execução registrado



Core finding / Conclusão central

A linha registrada demonstra que 98,01% do volume acumulado de entrada foi reportado como cache: 12.082.944 tokens cacheados contra 244.904 tokens novos.

The recorded line shows that 98.01% of cumulative input volume was reported as cached: 12,082,944 cached tokens versus 244,904 fresh tokens.

Evidence status / Situação da evidência: operational telemetry conditionally attributable to the Simplicio MCP session / telemetria operacional atribuível condicionalmente à sessão do Simplicio MCP.

1. Executive Summary / Resumo Executivo

98.01% Cached-input share Parcela de entrada em cache	12.08M Cached tokens Tokens cacheados	244.9K Fresh input Entrada nova	88.21% Illustrative input-cost reduction Redução ilustrativa do custo
---	---	---	---

Português O registro analisado contém uma quantidade muito alta de entrada reutilizada. Somando a entrada nova e a entrada cacheada, o volume acumulado de entrada foi de 12.327.848 tokens. Desses, 12.082.944 foram reportados como cache, resultando em uma parcela cacheada de 98,0134%.	English The analyzed record contains a very high amount of reused input. Adding fresh and cached input gives a cumulative input volume of 12,327,848 tokens. Of those, 12,082,944 were reported as cached, yielding a cached-input share of 98.0134%.
--	---

Interpretação correta Isso não significa 98% de redução no número de tokens enviados, nem 98% de economia financeira. Os tokens cacheados continuam compondo o contexto e aparecem na telemetria; o ganho é o reaproveitamento do processamento do prefixo repetido e a aplicação da tarifa de entrada cacheada quando houver cobrança por API.	Correct interpretation This does not mean a 98% reduction in tokens sent, nor a 98% financial saving. Cached tokens remain part of the context and telemetry; the benefit is reuse of processing for the repeated prefix and application of the cached-input rate when API billing applies.
---	---

Recommended evidence statement / Declaração recomendada “Em uma execução registrada do Simplicio MCP, 98,01% do volume acumulado de entrada foi reutilizado via cache.” “In a recorded Simplicio MCP execution, 98.01% of cumulative input volume was reused through cache.”
--

Nota técnica: 98,01% é uma parcela de tokens cacheados, não uma taxa de acerto por requisição. Para calcular cache-hit rate por chamadas, seriam necessários o número total de requisições e quantas tiveram cached_tokens > 0.

Technical note: 98.01% is a cached-token share, not a request-level cache-hit rate. Calculating request hit rate would require the total request count and the number of requests with cached_tokens > 0.

2. Evidence Record and Token Accounting / Registro de Evidência e Contabilização

USER-PROVIDED EXECUTION SUMMARY / RESUMO FORNECIDO PELO USUÁRIO

Token usage: total=297,222 input=244,904 (+ 12,082,944 cached) output=52,318 (reasoning 31,130)

Campo / Field	Valor / Value	Interpretação / Interpretation
total	297,222	Exactly equals fresh input + output / É exatamente entrada nova + saída
input	244,904	Fresh/uncached input shown in the displayed total / Entrada nova incluída no total exibido
cached	12,082,944	Cached input reported separately in parentheses / Entrada cacheada informada separadamente
output	52,318	Generated output including reasoning / Saída gerada, incluindo raciocínio
reasoning	31,130	Subset of output usage / Subconjunto da saída




Exact reconciliation / Reconciliação exata: 244,904 + 52,318 = 297,222

Arithmetic validation / Validação aritmética

O valor total exibido é reconciliado sem diferença: 244,904 + 52,318 = 297,222. A entrada cacheada aparece como uma dimensão acumulada separada.

The displayed total reconciles with no difference: 244,904 + 52,318 = 297,222. Cached input appears as a separate cumulative dimension.

3. Input Reuse Analysis / Análise de Reutilização da Entrada



Campo / Field	Valor / Value	Interpretação / Interpretation
Total input / Entrada total	12,327,848	Fresh + cached / Nova + cache
Cached-input share / Parcela cacheada	98.0134%	12,082,944 ÷ 12,327,848
Fresh-input share / Parcela nova	1.9866%	244,904 ÷ 12,327,848
Cached-to-fresh ratio / Razão cache:nova	49.34:1	Nearly fifty cached tokens per fresh token / Quase 50 cacheados por token novo

Leitura em português

Para cada token novo de entrada, aproximadamente 49,34 tokens foram reportados como reutilizados do cache. Esse padrão é compatível com um fluxo que mantém um prefixo extenso e estável - como instruções, ferramentas, schemas e histórico - enquanto adiciona uma parcela menor de informação variável.

English reading


For every fresh input token, approximately 49.34 tokens were reported as reused from cache. This pattern is consistent with a workflow that keeps a long, stable prefix - such as instructions, tools, schemas and history - while appending a smaller variable portion.

Important limitation / Limitação importante

O volume é acumulado entre chamadas. Ele não deve ser apresentado como uma única janela de contexto de 12,3 milhões de tokens.

The volume is cumulative across calls. It should not be presented as a single 12.3-million-token context window.

4. Output and Reasoning Analysis / Análise de Saída e Raciocínio




What this supports / O que isso sustenta

A execução realizou processamento substancial, e não apenas repetição de contexto: houve 52,3 mil tokens de saída, com 31,1 mil tokens de raciocínio.

The execution performed substantial processing rather than only repeating context: it produced 52.3K output tokens, including 31.1K reasoning tokens.

5. Cost Interpretation / Interpretação de Custo

Illustrative input-cost effect / Efeito ilustrativo no custo de entrada



Scenario assumption: cached input is priced at 10% of regular input. Excludes output, cache writes, tools and surcharges.
Premissa do cenário: entrada em cache custa 10% da entrada normal. Exclui saída, gravação de cache, ferramentas e adicionais.


Cálculo do cenário	Scenario calculation
Usando uma tarifa cacheada igual a 10% da tarifa normal de entrada, o custo normalizado da entrada seria: $(244,904 \times 1,0 + 12,082,944 \times 0,1) \div 12,327,848 = 11.7879$ unidades para cada 100 unidades sem cache. A redução ilustrativa é 88.2121%.	Using a cached-input rate equal to 10% of the regular input rate, normalized input cost would be: $(244,904 \times 1.0 + 12,082,944 \times 0.1) \div 12,327,848 = 11.7879$ units for every 100 no-cache units. The illustrative reduction is 88.2121%.

Not an invoice / Não é uma fatura	
A estimativa de 88,21% vale somente para o componente de entrada e sob a premissa de tarifa de cache de 10%. Ela não inclui saída, gravação de cache, ferramentas, modo de serviço, cobrança por contexto longo, impostos ou preço de outra plataforma. The 88.21% estimate applies only to input and under the 10% cached-rate assumption. It excludes output, cache writes, tools, service tier, long-context pricing, taxes and pricing from another platform.	
Formulação tecnicamente segura	Technically safe wording
“98,01% de reutilização da entrada e até aproximadamente 88,21% de redução estimada no custo de entrada neste cenário de preços.”	“98.01% input reuse and approximately 88.21% estimated input-cost reduction under this pricing scenario.”

A documentação atual da OpenAI informa que o prompt caching reutiliza prefixos exatos, reduz latência e aplica uma tarifa de entrada cacheada. A tabela pública de preços do GPT-5.6 lista entrada cacheada a 10% da entrada normal e gravações de cache a 1,25× da tarifa normal. [1][2]

Current OpenAI documentation states that prompt caching reuses exact prefixes, lowers latency and applies a cached-input rate. The public GPT-5.6 pricing table lists cached input at 10% of regular input and cache writes at 1.25× the regular rate. [1][2]

6. Evidence Strength and Attribution / Força da Evidência e Atribuição



Current status / Situação atual: strong operational indicator, not independent causal proof.
Indicador operacional forte, mas não é prova causal independente.

Evidence class / Classe	Claim / Afirmação	Assessment / Avaliação
Observed / Observado	12,082,944 cached tokens	Directly present in the supplied line / Presente diretamente na linha
Derived / Calculado	98.0134% cached-input share	Mathematically reproducible / Reproduzível matematicamente
Conditional / Condicional	Evidence of Simplicio MCP usage	Valid when provenance links the log to that MCP session / Válido quando a origem liga o log à sessão
Scenario / Cenário	88.2121% input-cost reduction	Depends on 10% cached-input pricing and exclusions / Depende da tarifa e das exclusões
Not established / Não comprovado	Simplicio alone caused all savings	Requires controlled A/B and trace correlation / Exige A/B controlado e correlação de rastros

Conclusão sobre o Simplicio MCP

Este registro é uma evidência operacional válida de que a sessão atribuída ao Simplicio MCP trabalhou com reutilização extensa de contexto. Entretanto, o mecanismo de cache é fornecido pelo provedor do modelo. O papel demonstrável do Simplicio é organizar a execução e preservar um contexto/prefixo reutilizável; a causalidade exclusiva requer comparação controlada.

Conclusion about Simplicio MCP

This record is valid operational evidence that the session attributed to Simplicio MCP operated with extensive context reuse. However, the cache mechanism is provided by the model provider. Simplicio's demonstrable role is to organize execution and preserve reusable context/prefixes; exclusive causality requires a controlled comparison.

Public claim recommended / Afirmação pública recomendada

“Telemetria de uma execução do Simplicio MCP registrou 12,08 milhões de tokens de entrada cacheados e 244,9 mil tokens novos, correspondendo a 98,01% de reutilização do volume de entrada.”

“Telemetry from a Simplicio MCP execution recorded 12.08 million cached input tokens and 244.9 thousand fresh input tokens, corresponding to 98.01% reuse of input volume.”

7. Reproducibility and Audit Package / Reprodutibilidade e Pacote de Auditoria

Para elevar a evidência

A linha atual sustenta a medição, mas um pacote auditável deve preservar a origem e permitir que terceiros refaçam os cálculos. Os itens abaixo transformam a evidência operacional em uma trilha técnica verificável.

To strengthen the evidence

The current line supports the measurement, but an audit-ready package should preserve provenance and allow third parties to reproduce the calculations. The items below turn operational evidence into a verifiable technical trail.

Português

- Salvar a resposta bruta de uso em JSON, sem edição.
- Registrar data/hora, session ID, request IDs e duração.
- Registrar versão/commit do Simplicio MCP e configuração ativa.
- Registrar modelo, provedor, service tier e política de cache.
- Separar cached_tokens, cache_write_tokens, input, output e tools.
- Executar A/B: mesmo trabalho com e sem o fluxo do Simplicio.
- Repetir várias vezes e publicar média, p50, p95 e variância.
- Gerar checksum SHA-256 para logs e relatório final.

English

- Save the raw usage response as unedited JSON.
- Record timestamp, session ID, request IDs and duration.
- Record the Simplicio MCP version/commit and active configuration.
- Record model, provider, service tier and cache policy.
- Separate cached_tokens, cache_write_tokens, input, output and tools.
- Run an A/B test: same work with and without the Simplicio workflow.
- Repeat runs and publish mean, p50, p95 and variance.
- Generate SHA-256 checksums for logs and the final report.

Minimum A/B result table / Tabela mínima do A/B

Publicar por execução: tokens novos, tokens cacheados, parcela cacheada, tokens de saída, tempo total, TTFT, custo estimado e erros. Usar exatamente o mesmo objetivo, repositório e modelo nos dois braços.

Publish per run: fresh tokens, cached tokens, cached share, output tokens, total time, TTFT, estimated cost and errors. Use the exact same objective, repository and model in both arms.

Critério sugerido: a afirmação “Simplicio reduz X%” deve usar a diferença mediana entre os braços A/B, com número de repetições e dispersão publicados. Esta linha isolada deve ser apresentada como estudo de caso observado.

Suggested criterion: the claim “Simplicio reduces X%” should use the median difference between A/B arms, with repetition count and dispersion published. This single line should be presented as an observed case study.

Appendix A. Reproducible Calculations / Apêndice A. Cálculos Reprodutíveis

Metric / Métrica	Formula / Fórmula	Result / Resultado
Displayed total / Total exibido	244,904 + 52,318	297,222
Total input volume / Volume total de entrada	244,904 + 12,082,944	12,327,848
Total token activity / Atividade total	12,327,848 + 52,318	12,380,166
Cached-input share / Parcela cacheada	12,082,944 ÷ 12,327,848	98.0134%
Fresh-input share / Parcela nova	244,904 ÷ 12,327,848	1.9866%
Reasoning share / Parcela de raciocínio	31,130 ÷ 52,318	59.5015%
Other output / Outra saída	52,318 - 31,130	21,188
Cached-to-fresh ratio / Razão cache:nova	12,082,944 ÷ 244,904	49.3375:1
Normalized input cost / Custo normalizado	(244,904 + 0.1 × 12,082,944) ÷ 12,327,848	11.7879%
Illustrative input saving / Economia ilustrativa	100% - 11.7879%	88.2121%

References / Referências

- [1] **OpenAI - Prompt Caching Guide.** <https://developers.openai.com/api/docs/guides/prompt-caching> Exact-prefix matching, cached_tokens monitoring, cache behavior. Accessed 24 August 2026.
- [2] **OpenAI - API Pricing.** <https://developers.openai.com/api/docs/pricing> GPT-5.6 cached-input and cache-write rates. Accessed 24 August 2026.
- [3] **Primary evidence / Evidência primária.** [User-provided execution line in this conversation](#). Token usage values transcribed verbatim into Section 2.

Document Control / Controle do Documento

Campo / Field	Valor / Value	Interpretação / Interpretation
Document ID / ID	SMCP-TOKEN-EVIDENCE-2026-08-24-v1	Versioned technical report / Relatório técnico versionado
Date / Data	24 August 2026	America/Sao_Paulo
Scope / Escopo	Single supplied usage summary	No raw request JSON or independent A/B baseline supplied
Conclusion / Conclusão	98.0134% cached-input share	88.2121% illustrative input-cost reduction under stated assumption

Final conclusion / Conclusão final

O registro é evidência quantitativa forte de reutilização de contexto na execução atribuída ao Simplicio MCP. A formulação correta é 98,01% de parcela cacheada da entrada; a economia financeira depende da tarifa e dos demais componentes da execução.

The record is strong quantitative evidence of context reuse in the execution attributed to Simplicio MCP. The correct formulation is a 98.01% cached share of input; financial savings depend on pricing and the other components of the execution.